2025

Aanbevelingen voor vervolgonderzoek

AI EV-BATTEIRJEN
TADRAŁA,PIOTR P.P.

O-PP-CMK

INHOUDSOPGAVE

1.0 INLEIDING

1.1 PROJECT CONTEXT

Het project is naar vooren gebacht door Hans Buurman die met een concrete vraag kwam, namelijk: Hoe kan een systeem worden ontwikkeld dat gebruikers in eerste instantie ondersteunt bij de handmatige controle van de kwaliteit van EV-batterijen door middel van röntgenbeelden, waarbij de gebruiker zelf fouten kan opsporen en markeren met behulp van de tools in de applicatie, en waarbij het ML-model naarmate er meer beelden gecontroleerd worden, effectief hulp biedt door het herkennen en voorspellen van defecten?

1.2 DOEL VAN DIT DOCUMENT

Dit document is opgesteld om een duidelijk overzicht te geven van de huidige stand van zaken van het projectn en om aanbevelingen te te geven voor een vervolgonderzoek. Bedoeling hiervan is dat de volgende student het werk makkelijk kan oppakken.

2.0 SAMENVATTING VAN DE VOORTGANG

2.1 WAT IS ER BEREIKT

ONDERZOEK

Er is uitgebreid onderzoek gedaan naar vier deelvragen met betrekking tot machine learning (ML), die eerst beantwoord moesten worden om een effectieve ML-implementatie te realiseren. De deelvragen zijn:

- Hoe wordt een AI-model ontwikkeld?
- Welke algoritmes zijn het meesst geschikt?
- Hoeveel data is er nodig voor het trainen van een AI-Model?
- Hoe kan de nauwkeurigheid van het AI-Model worden getest en gevalideerd?

ACCURACY & ARCHITECTURE ANALYSE

Er is een analyse uitgevoerd naar de correlatie tussen resolutie, hoeveelheid data en modelarchitectuur in relatie tot de nauwkeurigheid van het model. Hiervoor zijn tientallen modellen getraind en zijn de resultaten weergegeven in diagrammen.

ML LAYER DESIGN

Er is een design gemaakt voor de ML API Layer. daarin wordt beschreven wat de applicatie moet doen, wat de belangrijkste functionaliteiten van de applicatie zijn, welke endpoints beschikbaar zijn (inclusief een gedetailleerde beschrijving van hun functionaliteit), de input- en outputparameters, en een toelichting over de dataopslag.

PROOF OF CONCEPTS

Er zijn enkele demo's en proof-of-concepts (POC) ontwikkeld voor potentiële oplossingen waarmee we verder wilden werken. Resultaat hiervan zijn modellen en demo's voor data-augmentatie en -preprocessing, classification modellen en anomaly detection modellen.

WERKEND PROTOTYPE

Er is een werkend prototype ontwikkeld dat is geïntegreerd met zowel de frontend als de backend. Dit prototype maakt het mogelijk om CT-scans te analyseren met behulp van het ML model.

CI/CD PIPELINE & AZURE DEPLOYMENT

In GitHub is een monorepo opgezet waarin een CI/CD-pipeline is ingericht voor het automatisch builden, testen, approven en deployen van de code naar Azure. Daarnaast zijn een Azure-resource, container registry en web-app geconfigureerd, zodat code die naar de main branch in GitHub wordt gepusht, automatisch wordt gedeployed naar Azure.

ML ADVIES

Er is een advies- en integratiedocument opgesteld op basis van het onderzoek, waarin de beste oplossingen worden beschreven voor het trainen en integreren van het model in een applicatie.

3.0 OPENSTAANDE VRAGEN

WERKT DE VOORGESTELDE OPLOSSIN IN PRAKTIJK

De behaalde resultaten zijn gebaseerd op een zeer kleine dataset, waardoor het voor ons onmogelijk was te achterhalen of de oplossing in de praktijk net zo goed zou werken.

ANOMALY THRESHOLD OPTIMALISATIE

Tijdens het eindgesprek gaf een van de leden van INNER aan dat de huidige manier waarop de anomaly threshold wordt berekend geoptimaliseerd kan worden. Dit zou verder onderzocht kunnen worden om een efficiëntere methode te vinden.

AWS, GOOGLE & AZURE

Als feedback van INNER hebben we gehoord dat Google mogelijk een betere oplossing kan bieden dan Azure, vanwege lagere opslagkosten. Dit dient verder onderzocht te worden.

4.0 AANBEVELINGEN VOOR VERVOLGONDERZOEK

4.1 OPTIMALISATIE VAN DE ANOMALY DETECTION ALGORITME

De huidige model configuratie voor anomaly detection zou getest moeten worden op grotere datasets, en mogelijk moeten er layers aangepast worden om de accuracy te verhogen.

Daarnaast wordt de threshold berekend op basis van averages van goede en slechte data, wat volgens INNER geoptimaliseerd kan worden. Verder zijn er andere metrics, zoals KDE, die ook gebruikt kunnen worden voor het herkennen van anomalies. Hiernaar zou onderzoek moeten worden gedaan en, indien mogelijk, geïmplementeerd moeten worden.

4.2 PRECIEZE DEFECTEN HERKENNING

Een mogelijke uitbreiding van het huidige prototype is een precieze defectherkenning, waarbij het model specifiek aangeeft waar het een defect denkt te detecteren in een CT-scan.

4.3 BATTERIJ CLASSIFICATIE

Een potentiële manier om de anomaly detection te verbeteren is door eerst het type batterij te herkennen en vervolgens een specifiek anomaly detection-model te gebruiken dat is afgestemd op dat batterijtype.

4.4 VERGELIJKING VAN AWS, GOOGLE & AZURE

Gezien de feedback van INNER over lagere opslagkosten bij Google, is het aan te raden om een gedetailleerde vergelijking te maken tussen de cloud-oplossingen van AWS, Google en Azure.

5.0 CONCLUSIE

Het huidige resultaat sluit goed aan bij de originele onderzoeksvraag. Het ontwikkelde prototype ondersteunt gebruikers bij het analyseren van EV-batterijen met röntgenbeelden, waarbij het ML-model defecten herkent en voorspelt. Het onderzoek naar geschikte algoritmes, benodigde data en nauwkeurigheid heeft geleid tot een werkend prototype en een schaalbare infrastructuur met CI/CD-pipeline en Azure-deployment, wat de basis legt voor verdere ontwikkeling.